

Table of Contents

Veil 视频大纲 (中文版 · v3 · 对齐 v4.3 代码 · 8 类动作)

限时: 3 分钟以内 (180 秒硬上限) 评分: Clarity 10% + Technical 10% + Build 10% = 30% 受众: *general audience* (blog / open day), 不是 ML 专业听众 风格参考: Tether (Group 4) 的视频 — 真实 demo + 实拍 + 数据 callout 关键事实 (报告里全部一致): - 8 类动作: neutral / wink_left / wink_right / smile_big / surprise / frown / mouth_o / tongue_out - test_acc = 0.9905, macro-F1 = 0.9903 - 模型 32,168 参数, TF.js shard ≈ 128 KB - 封包 233 字节 / 帧 = 1B sender + 8B header + 16B head quat + 208B blendshape - 带宽 5.6 KB/s @ 24 Hz (Zoom 720p 的 0.37%) - 端到端延迟 P50 ≈ 33 ms 录制路径: ① 屏幕录 (OBS / QuickTime) ② 摄像头脸部小窗 (PIP) ③ iMovie / DaVinci 后期合成

整体结构 (6 个 Beat)

0:00	HOOK	15s	钩子 (一句问题 + 视觉冲击)
0:15	PROBLEM	30s	为什么要做 (Zoom 疲劳 + 隐私)
0:45	DEMO	45s	双浏览器实时配对 + 8 类表情同步
1:30	TECHNICAL	60s	数据 - 模型 - 部署 - 结果
2:30	REFLECTION	20s	学到什么 + 局限
2:50	CTA / SIGN-OFF	10s	GitHub 链接 + 一句愿景
3:00	END		3 分钟整, 严禁超时

每秒钟都要有事情发生。剪辑节奏: 平均每镜头 ≤ 4 秒。

Beat 1 · HOOK (0:00-0:15 · 15 秒)

画面

- [镜头 1 · 0:00-0:05] 全屏 Zoom 通话画面 (用 Pexels “video call” 关键词的 stock 视频, 或自己另一台设备拍 Zoom 截屏)。画外音不响, 镜头中人在尴尬地盯自己脸。
- [镜头 2 · 0:05-0:10] 摄像头突然被一只手盖住 (隐私手势), 屏幕变黑。这一帧要 **干净一帧到位**, 不要犹豫。
- [镜头 3 · 0:10-0:15] 黑屏中 Veil logo 淡入, 3D avatar 旋转出现 + 跟着我笑。

旁白

“We’ve all done this. Camera on, camera off, hide. There has to be a third way.” (我们都干过这事 — 开摄像头、关摄像头、躲。应该有第三条路。)

屏上文字 (lower-third 大字)

时间

0:00

0:10

[截图 V-1 · Veil logo 静帧] — 你 mobile_avatar.html 顶栏的“VEIL”紫色字 + 一个 avatar 头像,作为转场用的 vector。

Beat 2 · PROBLEM (0:15-0:45 · 30 秒)

画面切换 (~每 5-7 秒一镜头)

- [镜头 4 · 0:15-0:20] 数据可视化: “Mehrabian 55% rule” pie chart 动画 (浮 in 三块: 55% body language / 38% tone / 7% words)。建议用 D3 / Recharts / Keynote magic-move。
- [镜头 5 · 0:20-0:25] 一行文字 typewriter 动画: Zoom: 1,500 KB/s · Veil: 5.6 KB/s · 0.37%
- [镜头 6 · 0:25-0:32] 新闻标题剪辑: “Zoom Fatigue is Real” / “64% of remote workers turn off camera for privacy”(IPSOS 2023 数字)。
- [镜头 7 · 0:32-0:40] 切到我 (主讲人脸),坐桌前直视摄像头。≤ 8 秒。
- [镜头 8 · 0:40-0:45] 切到屏幕 — 展示 Veil 启动页 hero ([截图 V-2])。

旁白

“Mehrabian showed in 1971 that more than half of what we *say* is actually our face. So when we keep cameras on, we leak everything — environment, mood, fatigue. (pause) Veil’s question is simple: can we keep the *expression* and drop the *pixels*?” (Mehrabian 1971 年证明,我们说出口的话里超过一半其实是脸传达的。所以摄像头开着的时候,我们泄露的是一切 — 环境、心情、疲惫。Veil 的问题很简单: 能不能留下表情,丢掉像素?)

屏上文字

时间

0:18

0:23

0:32

0:42

录制要点

- 镜头 4 的 pie chart 用 magic-move 比“飞入飞出”显贵。
- 镜头 7 直视摄像头 ≤ 8 秒,不要演讲腔。
- 数字是钩子,不要念全句,屏幕上要打出来。

[截图 V-2 · 启动页 hero] — http://localhost:8080/mobile_avatar.html?local=1 加载完成那一帧,VEIL logo + “Be together, stay private” + 那 3 步引导卡。你截一下。

Beat 3 · DEMO (0:45-1:30 · 45 秒) ★ 这一节决定 Quality of Build 10 分

画面 — 这是整支视频的核心

录制要求: 屏幕录用 **60 fps + 1080p+** OBS scene 同时录 Chrome + Safari + 我的脸 (画中画 200×200)。

- [镜头 9 · 0:45-0:55] 屏幕分屏: 左 Chrome 右 Safari, 两个都打开 mobile_avatar.html。我演示在两个窗口分别填名字 / room code (同一个 room code), 分别选不同 avatar (左 Mira GLB 右 V-1 VRM)。
- [镜头 10 · 0:55-1:05] 两个窗口都点 “Allow camera & enter room”, 顶部 pill 从 **waiting** 变 **paired** (绿)。这一帧要慢放 **0.5×**。
- [镜头 11 · 1:05-1:25] 我做出 **5** 个动作, 两个窗口里两个 avatar 同步跟着动。每个动作 3-4 秒:
 - smile_big (1:05-1:09)
 - surprise (1:09-1:13)
 - wink_left (1:13-1:17)
 - mouth_o (1:17-1:21)
 - tongue_out (1:21-1:25)
- [镜头 12 · 1:25-1:28] 双方同时 smile_big → 中央爆出 mood-sync emoji 动画。
- [镜头 13 · 1:28-1:30] 镜头特写底部 ~5.5 KB/s bandwidth pill, 后期加红圈 + arrow 指。

旁白

“Two browsers. Same room code. Different avatars. (pause) Watch — when I smile, my avatar smiles. Wink, surprise, mouth-O, tongue-out — eight discrete actions, recognised entirely in the browser. When my partner smiles too — that little burst is mood sync, fired only when both ends agree. And the bandwidth — five-point-six kilobytes per second. Two-hundred-fifty times less than a Zoom call.” (两个浏览器, 同一个房间码, 不同的化身。看 — 我笑, 我的化身就笑。挤眼、惊讶、张嘴 O、吐舌 — 8 个离散动作, 完全在浏览器里识别。当我的搭档也笑 — 中间这个爆发就是 mood sync, 只在双方都同意时触发。带宽 — 每秒 5.6 KB, 比 Zoom 少 250 倍。)

屏上文字 (callout)

时间

0:48

0:58

1:05

1:18

1:25

1:28

录制要点 (Build 10 分的关键)

1. 必须是真实双窗口实时配对,不要后期合成。评分老师从画面流畅度看得出。
2. mood-sync 那一帧要预先彩排过 — 真实情况下两人需要同时笑,可能要重录几遍才能对齐。
3. bandwidth pill 那一刻镜头 **zoom in** 到 5.6 KB/s 这几个字,后期加红圈 + arrow。
4. 5 个动作全做齐 — 这是把视频从“我训了一个二分类”升级成“我训了一个 8 分类”的关键差异点,直接对应 Technical 10 分。

截图清单

- [截图 V-3 · Demo 主截图] — 双浏览器并排 paired 状态。这一张做缩略图也用得上。
 - [截图 V-4 · 5 个动作合成] — 9-cell grid: 第 1 列我的脸 5 行,第 2 列左 avatar 5 行,第 3 列右 avatar 5 行。证明模型真的能识别 8 类而不是只笑一种。
 - [截图 V-5 · mood-sync 触发瞬间]。
 - [截图 V-6 · 5.6 KB/s bandwidth pill 特写]。
-

Beat 4 · TECHNICAL OVERVIEW (1:30-2:30 · 60 秒) ★ 这一节决定 Technical 10 分

Sub-beat 4.1 (1:30-1:42 · 12s) 数据 + 管线

[镜头 14 · 1:30-1:42] 切到 [Fig 2 数据管线图] 全屏,逐 stage 高亮: Camera Frame → 468 Landmarks → 52 Blendshapes → 30-frame Window → 1D-CNN → 8-way softmax。每 stage 高亮 ~2 秒。

旁白: > “MediaPipe extracts four-hundred-sixty-eight facial landmarks per frame, condensed into fifty-two ARKit blendshapes — the same vocabulary Animoji uses. Thirty frames stack into a one-second window, fed to the network.”

屏上文字: 468 → 52 in 22 ms · all on-device

Sub-beat 4.2 (1:42-1:54 · 12s) 模型架构

[镜头 15 · 1:42-1:54] 切到 [Fig 3 1D-CNN 架构图]。逐层 reveal: Conv → BN → Conv → BN → Conv → BN → GAP → Dropout → Dense(8, softmax)。

旁白: > “A small 1D CNN — thirty-two thousand parameters, three milliseconds per inference. Trained on six hundred synthetic sessions across eight action classes.”

屏上文字: - 1:45 1D-CNN · 32,168 params · 8 classes - 1:50 TF.js shard: 128 KB · inference: 2.8 ms

Sub-beat 4.3 (1:54-2:10 · 16s) 训练 + 结果

[镜头 16 · 1:54-2:02] 切到 [Fig 4 训练曲线], loss 单调下降 + acc 上升动画 (用 artifacts/training_history.png)。[镜头 17 · 2:02-2:10] 切到 [Fig 5 混淆矩阵] heatmap (用 artifacts/confusion_matrix.png), 对角线 312 / 315 全亮。

旁白: > “Test accuracy: ninety-nine point oh five percent on three hundred fifteen windows. (pause) But honest disclosure — the split is by window, not by actor. On real strangers it drops to about eighty-four. Generalisation is where edge AI gets honest.” > (测试准确率 99.05%, 基于 315 个窗口。但坦白说 — 这是按窗口切分, 不是按人。在真正陌生人身上掉到 ~84%。泛化才是 edge AI 真正诚实的地方。)

屏上文字: - 2:00 Test acc: 99.05% · macro-F1: 0.9903 · 315 windows - 2:07 wild-test on strangers: ~84% — generalisation gap

Sub-beat 4.4 (2:10-2:30 · 20s) 部署 + 多用户协议

[镜头 18 · 2:10-2:18] 切到 [Fig 1 三层架构图], 红色虚线圈出“本地”区域 + 绿色虚线圈出“穿网区域”。[镜头 19 · 2:18-2:25] 切到 Chrome DevTools → Network → WS 那栏, 看到一行 233 bytes 的 binary frame。[镜头 20 · 2:25-2:30] 屏幕回到双 avatar 实时画面。

旁白: > “Each frame travels as two-hundred-thirty-three bytes — header, head pose quaternion, fifty-two floats. No pixels ever leave the device. The relay never sees a face.” > (每一帧只有 233 字节 — 包头、头部姿态四元数、52 个浮点。像素从不离开设备。中继服务永远看不到一张脸。)

屏上文字: - 2:15 Per-frame packet: 1B sender + 8B header + 16B quat + 208B blendshapes = 233B - 2:23 Zero pixels uploaded — by design

[截图 V-7 · DevTools Network WS 面板] — Chrome DevTools → Network → WS, 看到 233 bytes 的 binary frame 那一行。你截一下。

Sub-beat 4 录制要点

- 5 张图 (架构 1 + 数据管线 2 + 模型 3 + 训练曲线 4 + 混淆矩阵 5) 事先做好高分辨率 PNG, 后期用 Keynote magic-move 切换。
 - 不要用整张 PowerPoint, 用全屏 PNG + 标注 overlay。
 - 旁白节奏每 sub-beat 不超过 12-16 秒, 留 2-3 秒缓冲。
-

Beat 5 · REFLECTION (2:30-2:50 · 20 秒)

画面

- [镜头 21 · 2:30-2:40] 切到我本人镜头 (直视), 手势自然。背景: 桌面有 Mac + 开发者氛围 (笔记本、咖啡)。
- [镜头 22 · 2:40-2:50] 切到一段 *frown* 误判为 *wink_left* 的实际混淆样本视频 (我自己录的反面案例), 屏幕上叠红框 + “misclassified” 文字。

旁白

“Two honest limitations. One — the test split was by window, not by person; my real cross-subject score is closer to eighty-four. Two — ARKit’s fifty-two blendshapes don’t have an ‘anger’ channel, so frown and angry collapse together. Both are fixable — but they’re real.” (两个诚实的局限。—— 测试切分是按窗口而不是按人, 真正的跨人测试分数更接近 84%。二 — ARKit 的 52 个 blendshape

里没有“愤怒”通道,所以 frown 和 angry 会塌成同一个。两个都能修 — 但它们真实存在。)

屏上文字

- 2:32 Limitation 1: by-window split — cross-subject $\approx 84\%$
- 2:42 Limitation 2: 'anger' has no native blendshape channel

录制要点

- 这一节是 mark scheme 看 *clarity of presentation* 的地方 — 承认局限会加分,不要吹。
- 如果时间紧,这一段可以省到 15 秒 (20 $\rightarrow$ 15),把多出来的 5 秒并到 Beat 3 Demo。

[截图 V-8 · frown $\rightarrow$ wink_left 误判录屏静帧] — 我面部明显皱眉,但 avatar 显示左眼挤眼,旁边 confidence vector 显示 wink_left:0.51 / frown:0.47。你需要彩排录这段反面 case。

Beat 6 · CTA / SIGN-OFF (2:50-3:00 · 10 秒)

画面

- [镜头 23 · 2:50-2:58] 全屏 logo 动画 + 三行 CTA。
- [镜头 24 · 2:58-3:00] 暗场 + Veil 单字 logo 收尾。

屏上文字 (大字)

Veil — be together, stay private
github.com/<user>/Veil
CASA0018 · UCL · 2025

旁白

“Veil. Be together, stay private. Code’s on GitHub.”

录制 + 后期 checklist

录制

- ☐ OBS 双场景: Scene A = 双浏览器 + 我脸 PIP; Scene B = 全屏 PPT/图
- ☐ 1080p / 60fps / H.264 / AAC 48kHz
- ☐ 环境光从前打 (避免 MediaPipe 在我脸上掉点)
- ☐ 麦克风用 Mac 自带 + iPhone 备份 (怕一台坏)
- ☐ 录之前先把脚本逐字念一遍,然后再做 demo,声画分轨录
- ☐ **Beat 3 demo** 至少录 **3 take** — 挑配对最快、5 个动作最准、mood-sync 最干净的那条
- ☐ 录前先 localStorage.clear() 清掉旧 avatar 设置,避免演示时窗口自动跳到旧选择

后期 (iMovie / Resolve / FCPX 任选)

- ☐ 把每个 beat 的镜头放到对应轨道,先对时长再对内容

- ☐ 加屏上文字 (lower-third + 大字 callout) — 没有屏字 clarity 拿不到 8/10
- ☐ BGM 极轻 (-25 dB), 不要有人声 / 歌词 / 强节拍 干扰旁白
- ☐ 旁白录完后用 **Audacity** 降噪 + **compressor** 让音量统一
- ☐ 最后渲染前关声音播一遍, 看是否仅看画面就能 follow story (clarity 评分点)
- ☐ 检查时长 ≤ 180 秒 严格遵守 — 超时直接扣 clarity 分

上传

- ☐ YouTube unlisted 或 UCL OneDrive 共享链接
 - ☐ 视频描述里贴: GitHub link + Veil 一句 tagline + CASA0018 标签
 - ☐ **GitHub README** 里嵌一个视频 **thumbnail** 链接 — Build 项 +1 pt 点
-

评分项映射 (每个 beat 命中哪个评分点)

Beat

1 Hook

2 Problem

3 **Demo**

4 **Technical**

5 Reflection

6 CTA

如果时间紧迫只能砍 1 个 beat: 保留 **3 + 4**, 牺牲 **2** — 视频开头多 5 秒 hook 直接进 demo。

截图 / 图清单 (视频专用, 跟报告不重复)

编号

截图 V-1

截图 V-2

截图 V-3

截图 V-4

截图 V-5

截图 V-6

截图 V-7

截图 V-8

Fig 1 (复用报告)

Fig 2 (复用报告)

Fig 3 (复用报告)

Fig 4 (复用报告)

Fig 5 (复用报告)

一句话录制顺序建议

先把 **Beat 3 Demo** 录通顺 (双浏览器配对 + 5 个动作 + mood-sync 三件事), 其它 beat 都好补; Demo 砸了整支视频就废一半分。

Beat 3 demo 的彩排 checklist (录之前过 5 遍)

1. 配对 ≤ 2 秒: 两个窗口同时点 Go, Pill 在 2 秒内变绿。如果你的相机授权慢, 先把两窗口都 Allow 一次摄像头让 Chrome / Safari 记住。
 2. 8 类动作的可识别度 (录之前自己测一遍每个动作 confidence ≥ 0.5):
 - smile_big — 嘴角咧到耳朵, 牙齿露出来
 - surprise — 眉毛上扬 + 嘴张开 (不是 mouth_o)
 - wink_left — 单独闭左眼, 右眼睁 (注意 MediaPipe 视角是镜像)
 - wink_right — 单独闭右眼
 - mouth_o — 嘴撅成圆形 (“oh”)
 - tongue_out — 伸舌头 (这是最显眼的, 一定要录)
 - frown — 眉头紧锁 + 嘴角下垂
 - neutral — 静止 (用来做对照)
 3. **mood-sync** 触发: 两人同时做 smile_big, 保持 ≥ 1 秒, 中央会出。如果第一次没触发, 看看双方 confidence 都 ≥ 0.5 (代码 CONF_THRESHOLD = 0.5)。
 4. **bandwidth pill** 显示: 顶部 pill 旁边的 ~5.5 KB/s 是底部 stats bar 计算的。录的时候别让网络抖动让数字飘到 7+, 可以提前重启 relay。
 5. 录 **3 take** 留备: 第 1 take 试错, 第 2/3 take 正式。
-

视频引用图汇总 / Figures referenced in this video

Veil · three-layer system architecture





图 / Fig 1 · 系统架构 / system architecture

Data + inference pipeline (per frame, in-browser)



Total end-to-end median latency = 33.5 ms (well under 33.3 ms / 30 fps budget)

图 / Fig 2 · 数据管线 / data pipeline

1D-CNN architecture · total = 32,168 params · 165 KB H5 / ~128 KB TF.js shard




图 / Fig 3 · 1D-CNN 架构 / 1D-CNN architecture




图 / Fig 4 · 训练曲线 / training history




图 / Fig 5 · 混淆矩阵 / confusion matrix




图 / Fig 6 · 类级 P/R/F1 / per-class P/R/F1




图 / Fig 7 · 消融对比 / ablation

End-to-end latency: cam → remote avatar = 33.5 ms (P50) — well under 33.3 ms / 30 fps threshold




图 / Fig 8 · 端到端延迟 / end-to-end latency

Veil sends 0.37 % of a 720p Zoom call — 233 bytes × 24 Hz = 5.6 KB/s





图 / Fig 9 · 带宽对比 / bandwidth comparison

encodePacket() · 233 B per frame · @ 24 Hz → 5.6 KB/s



① sender id (relay) · ② action idx · ③ header (reserved) · ④ head pose quaternion (xyzw) · ⑤ 52 × float32 ARKit blendshapes

Field widths drawn at √(size) scale so the 1-byte fields stay legible.

The actual 208 B blendshape payload is ≈ 89 % of the packet — header overhead is < 11 %.

图 / Fig 10 · 封包结构 / packet anatomy




图 / Fig 11 · 数据集平衡 / dataset class balance